

산불 위험 예측 데이터 전처리 요약 보고서

PREP_01 ~ PREP_05 노트북 기반

1. 요약

본 보고서는 PREP_01_스케일변환.ipynb 부터 PREP_05_DWI 기상위험지수.ipynb 까지의 전처리 흐름을 정리한 문서이다. 전처리의 목적은 기상청 격자 기상자료를 실제 물리 단위로 변환하고, 산불위험지수 산출에 필요한 실효습도, 강우효과, 일가중치, DWI 기상위험지수를 생성하는 것이다.

분석 및 전처리 대상은 2025 년 2 월~5 월의 강원도 100m 격자-일 단위 데이터이며, 전체 처리 규모는 32,760,120 행이다. 전처리 결과물은 이후 FMI, TMI, PEI 등 공간-전력설비 위험지수와 결합하여 최종 P-FFDRI 산출에 사용할 수 있다.

구분	결과물	주요 처리	검증 결과
PREP_01	weather_scaled/	12 개 기상 변수 ÷10 스케일 변환	전체 32,760,120 행 범위 정상
PREP_02	derived/effective_humidity/	현재+과거 4 일 상대습도 가중합	결측 0 개, 0~100% 범위 정상
PREP_03	derived/rne/	최근 3 일 강수 등급 기반 RNE 산출	RNE 값 0.1~1.0, 월별 분포 확인
PREP_04	derived/w_d.parquet	월/일 기준 계절 가중치 생성	120 일 × 2 컬럼 저장 확인
PREP_05	derived/dwi/	PreDWI, 등급화, RNE 반영 DWI 생성	4 월 평균 DWI 4.11, 고위험 13.7%

2. 입력 데이터와 처리 범위

입력 데이터는 grid_date_master 의 월별 파티션 데이터이며, 전처리 노트북에서는 2025-02, 2025-03, 2025-04, 2025-05 네 개 월을 대상으로 처리했다. 각 월별 행 수는 다음과 같다.

월	행 수	비고
2025-02	7,644,028	28 일
2025-03	8,463,031	31 일
2025-04	8,190,030	30 일
2025-05	8,463,031	31 일
합계	32,760,120	120 일

격자 수는 월별 일수와 행 수를 역산하면 약 273,001 개로 일관되게 나타난다. 실효습도와 RNE 계산에서는 월 경계의 연속성을 보장하기 위해 이전 달 마지막 며칠을 버퍼로 붙여 계산한 뒤, 저장 시 해당 월 데이터만 남겼다.

3. 단계별 전처리 내용

3.1 PREP_01 — 스케일 변환

기상청 원본 격자자료는 파일 크기 절감을 위해 일부 수치가 실제값의 10 배 또는 정수형 스케일로 저장되어 있다. 이에 따라 기온, 습도, 이슬점온도, 풍속, 강수량 관련 12 개 컬럼을 ÷10 처리하여 실제 물리 단위로 복원했다.

변환 컬럼군	변환	단위/의미
ta_mean, ta_max	÷10	기온(°C)
hm_mean, hm_min	÷10	상대습도(%)
td_mean, td_min	÷10	이슬점온도(°C)
wind_ws_mean, wind_ws_max	÷10	풍속(m/s)
wind_uu_mean, wind_vv_mean	÷10	동서/남북 풍속 성분(m/s)
rn_day_mean, rn_day_max	÷10	강수량(mm)
wind_wd_sin_mean, wind_wd_cos_mean	변환 없음	이미 -1~1 범위의 원형 평균 성분

검증 결과, 변환 후 전체 32,760,120 행 기준으로 기온, 습도, 풍속, 강수량이 현실적인 범위에 들어왔다. 예를 들어 ta_mean 은 -19.36~27.16°C, hm_mean 은 14.07~100.00%, wind_ws_mean 은 0.05~8.93m/s, rn_day_mean 은 0.00~22.24mm 범위로 확인되었다.

저장 방식은 월별 파티션이며, 저장 위치는 weather_scaled/이다. 파일 크기는 원본 595.2MB 에서 변환 후 580.2MB 로 소폭 감소했다. float32 변환을 적용했지만, Parquet 압축과 컬럼 구조 특성상 절반 수준의 감소는 발생하지 않았다.

3.2 PREP_02 — 실효습도 생성

실효습도는 당일 습도만이 아니라 과거 며칠간의 습도 상태를 함께 반영하는 건조도 지표이다. 산불 위험은 오늘의 습도뿐 아니라 이전 며칠간의 건조 지속 여부에 영향을 받으므로, DWI 산출에 필요한 핵심 파생변수로 생성했다.

계산식은 다음과 같다: $EH = 0.3 \times (H_0 + 0.7 \times H_1 + 0.49 \times H_2 + 0.343 \times H_3 + 0.2401 \times H_4)$. 여기서 H_0 는 당일 평균 상대습도, $H_1 \sim H_4$ 는 각각 1~4 일 전 평균 상대습도이다.

- 격자별로 grid_id, date 기준 정렬 후 lag 변수를 생성했다.
- 월 경계 처리를 위해 3 월 계산 시 2 월 마지막 4 일, 4 월 계산 시 3 월 마지막 4 일을 버퍼로 붙였다.
- 데이터 시작 초반 4 일처럼 과거값이 없는 구간은 당일값으로 채워 보수적으로 처리했다.

검증 결과 결측치는 0 개였고, 실효습도 범위는 0~100%로 정상 판정되었다. 월별 처리 시간은 약 8.4~10.0 초였으며, 각 월별 결과는 derived/effective_humidity/month=YYYY-MM/data.parquet 형태로 저장되었다.

3.3 PREP_03 — 강우효과 RNE 생성

RNE 는 최근 3 일간의 강수 상태가 산불위험을 얼마나 낮추는지 표현하는 감쇠 계수이다. 비가 없으면 RNE=1.0 으로 위험도를 그대로 유지하고, 최근 3 일 동안 강수가 많을수록 0.5, 0.4, 0.3, 0.2, 0.1 로 낮아진다.

단계	내용
강수 등급	<1mm=0, 1~5mm=1, 5~10mm=2, 10mm 이상=3
RNE_Temp	등급(2 일전) + 등급(1 일전) + 등급(당일)
RNE 변환	RNE_Temp <2: 1.0, <3: 0.5, <4: 0.4, <5: 0.3, <6: 0.2, 6 이상: 0.1

RNE 역시 월별 처리와 2 일 버퍼 이월 방식을 사용했다. 검증 샘플에서는 5mm 이상 강수일 이후 rne_temp 가 상승하고, 그에 따라 RNE 가 낮아지는 흐름이 확인되었다.

월	RNE=1.0 비율	RNE<1.0 비율	해석
2025-02	100.0%	0.0%	최근 3 일 강수 감쇠 없음
2025-03	92.0%	8.0%	일부 강수 영향 발생
2025-04	81.5%	18.5%	강수 영향 증가
2025-05	71.3%	28.7%	봄비 영향으로 위험 감쇠 확대

3.4 PREP_04 — 일가중치 w_d 생성

w_d 는 계절별 산불 발생 위험도를 반영하는 날짜 단위 가중치이다. 본 데이터 기간인 2025 년 2 월~5 월에 대해서는 총 120 행의 date-w_d 테이블을 생성했다. 모든 격자에 동일하게 적용되는 날짜 기준 값이므로 대용량 격자 데이터에 반복 저장하지 않고 별도 테이블로 관리했다.

w_d	적용 기간	일수	위험 수준
1.00	3 월 21 일~4 월 10 일	21 일	최고
0.95	3 월 11~20 일, 4 월 11~20 일	20 일	높음
0.90	3 월 1~10 일, 4 월 21~30 일	20 일	중간
0.85	2 월 전체, 5 월 전체	59 일	중간

저장 위치는 derived/w_d.parquet 이며, 크기는 약 2.7KB 이다. 향후 최종 위험지수 산출 단계에서 date 기준으로 병합하면 된다.

3.5 PREP_05 — DWI 기상위험지수 생성

DWI 는 기온, 상대습도, 실효습도, 평균풍속을 이용해 계산한 PreDWI 를 1~10 등급으로 재분류한 뒤, RNE 강우효과를 반영하여 산출했다. 이 단계에서는 w_d 를 곱하지 않고, DWI = PreDWI 등급 × RNE 형태로 저장했다.

봄철 PreDWI 계산식은 다음과 같다: $\text{PreDWI} = \text{sigmoid}(2.706 + 0.088 \times \text{평균기온} - 0.055 \times \text{상대습도} - 0.023 \times \text{실효습도} - 0.104 \times \text{평균풍속})$. 이후 산림청 봄철 기준 구간으로 1~10 등급화했다.

월	평균 DWI	해석
2025-02	2.66	추운 겨울, PreDWI 낮음
2025-03	3.00	봄철 건조 시작
2025-04	4.11	기온 상승과 건조 지속으로 최고
2025-05	2.81	봄비 효과로 감소

DWI 결과는 derived/dwi/에 월별 파티션으로 저장되었고, 컬럼은 grid_id, date, predwi, predwi_class, dwi 이다.
4 월의 고위험($DWI \geq 8$) 격자 비율은 13.7%로 나타나 산불 최고 위험기와 부합하는 패턴을 보였다.

4. 산출물 구조

경로	주요 컬럼	행 수/규모	용도
weather_scaled/	grid_id, date, ta_mean, hm_mean, wind_ws_mean 등	32,760,120 행	실제 단위 기상자료
derived/effective_humidity/	grid_id, date, effective_humidity	32,760,120 행	DWI 입력 변수
derived/rne/	grid_id, date, rn_class, rne_temp, rne	32,760,120 행	강우 감쇠 계수
derived/w_d.parquet	date, w_d	120 행	최종 위험지수 계절 가중치
derived/dwi/	grid_id, date, predwi, predwi_class, dwi	32,760,120 행	기상위험지수

5. 검증 결과 요약

- 스케일 변환 후 모든 주요 기상 컬럼이 현실적인 허용 범위 안에 들어왔다.
- 실효습도는 결측 0 개이며 0~100% 범위 검증을 통과했다.
- RNE 는 공식상 가능한 값 집합 안에서만 생성되었고, 강수 후 RNE 가 낮아지는 샘플 시계열 검증을 통과했다.
- w_d 는 2025 년 2 월~5 월 120 일 전체에 대해 누락 없이 생성되었다.
- DWI 는 4 월 평균이 가장 높고 5 월에 감소하여 계절성과 강우효과가 반영된 결과를 보였다.

6. 확인이 필요한 부분 및 개선 제안

주의 사항

- PREP_04 설명에는 $DWI = \text{PreDWI 등급} \times RNE \times w_d$ 라고 적힌 부분이 있으나, PREP_05 구현과 공식 흐름상 w_d 는 최종 통합 위험지수 단계에서 적용하는 것이 더 일관적이다.
- 현재 전처리 노트북은 2025 년 2~5 월만 처리한다. 전체 데이터가 2020~2025 년 봄철이라면 동일 파이프라인을 모든 연도에 확장해야 한다.
- RNE 는 rn_day_mean 을 기준으로 등급화했다. 공식의 시간당 강수 또는 누적강수 정의와 완전히 일치하는지 추가 확인이 필요하다.
- master_grid 의 grid_id 중복 문제가 남아 있다면, DWI 와 공간 변수 병합 전 반드시 grid_id 유일성을 보장해야 한다.

추가로, 최종 P-FFDRI 산출 시 DWI 외에 FMI(임상), TMI(지형), PEI(전력설비 위험)를 같은 grid_id-date 기준으로 결합해야 한다. 이때 공간 변수는 날짜별로 반복 결합되는 정적 변수이므로, merge 전후 행 수가 변하지 않는지 검증하는 절차가 필요하다.

7. 다음 작업 제안

우선순위	작업	목적
1	전 연도(2020~2025) 전처리 확장	모델 학습용 시계열 표본 확대
2	master_grid 중복 정리	공간 변수 merge 왜곡 방지
3	FMI/TMI 산출 테이블 생성	임상·지형 위험 반영
4	산불발생이력과 grid-date 라벨 결합	지도학습용 y 생성
5	최종 P-FFDRI 및 ML 피쳐셋 생성	모델링 입력 데이터 완성

8. 결론

PREP_01~PREP_05 를 통해 원본 기상 격자자료는 실제 단위로 변환되었고, 산불위험지수 산출에 필요한 핵심 기상 파생변수인 실효습도, 강우효과 RNE, 일가중치 w_d , DWI 가 생성되었다. 특히 DWI 의 월별 패턴은 4 월 최고, 5 월 감소로 나타나 산불위험의 계절성과 강우효과가 일정 수준 반영된 것으로 판단된다.

다만 현재 결과는 2025 년 2~5 월 기준이며, 최종 모델링 전에는 전 연도 확장, 공간 마스터 중복 정리, 산불발생이력 라벨 결합, 최종 P-FFDRI 산식 적합성 검증이 필요하다.

부록. 참고한 노트북

- PREP_01_스케일변환.ipynb
- PREP_02_실효습도.ipynb
- PREP_03_강우효과 RNE.ipynb
- PREP_04_일가중치 WD.ipynb
- PREP_05_DWI 기상위험지수.ipynb

공식 참고자료: 국가산불위험예보시스템 위험지수 산출 알고리즘 설명(산불연구과, 2026.04.20), Won et al. (2010) Development and Application of a Forest Fire Danger Rating System in South Korea.